

Proposal

구현팀 전달 문서: Task-Family-Aware KD Signal Analysis

1. 최종 확정 결정사항

항목	결정
실험 설계	Logit x Hidden x Attention 의 $2^3 = 8$ TinyBERT-style crossed factorial ablation
공통 supervised loss	Cross Entropy 는 모든 조건에 포함
Student checkpoint	공개 TinyBERT_General_4L_312D 사용
TinyBERT exact reproduction	하지 않음
Task-specific training	순차 학습이 아님. 활성화된 모든 loss를 한 번에 넣고 학습
Random-init baseline	제외
Data augmentation	제외
Seed	42
Hyperparameter search	없음. 하나의 HP 세트를 모든 dataset/condition에 공유
KD temperature	$T = 1.0$
Loss weights	$w_{ce} = w_{logit} = w_{hidden} = w_{attention} = 1.0$
Teacher	dataset별 bert-base-uncased fine-tuning 후 freeze
Student	모든 condition에서 같은 public TinyBERT checkpoint로 시작
Tokenizer	bert-base-uncased tokenizer
Layer mapping	student 1 -> teacher 3, 2 -> 6, 3 -> 9, 4 -> 12
Early stopping	teacher와 student 모두 사용 가능. 단, student는 모든 condition에 같은 monitor/patience/rule 적용
Primary metric	macro-F1
필수 secondary metric	micro-F1, accuracy, per-class F1, confusion matrix

2. 실험 조건표

CE는 모든 조건에서 항상 ON이다. 세 factor는 Logit, Hidden, Attention이다.

Condition	Binary (L,H,A)	CE	Logit KD	Hidden KD	Attention KD
ce_only	000	ON	OFF	OFF	OFF
kd_logit	100	ON	ON	OFF	OFF
kd_hidden	010	ON	OFF	ON	OFF
kd_attn	001	ON	OFF	OFF	ON
kd_logit_hidden	110	ON	ON	ON	OFF
kd_logit_attn	101	ON	ON	OFF	ON
kd_hidden_attn	011	ON	OFF	ON	ON
kd_full	111	ON	ON	ON	ON

3. Dataset 계약

구현 목표는 main 9개 dataset이다. 모든 dataset adapter는 최종적으로 train, dev, test split을 노출해야 한다. official split이 없거나 dev가 없으면 seed 42로 stratified split을 생성하고 split index/hash를 저장한다.

Family	Dataset	Official link	Loader/HF 후보	Input	Label	O
Hate speech	DynaHate	GitHub data, paper	official CSV 직접 로드 권장. HF mirror는 검증 후 사용	single text	binary 또는 multi-class, adapter에서 확정	C o i t s r e 고

Family	Dataset	Official link	Loader/HF 후보	Input	Label	O
Hate speech	Davidson hate/offensive	GitHub data, paper	custom/local	single text	hate/offensive/neither	or se t in
Hate speech	HatEval	HF gated data, paper	custom/local 또는 HF gated	social media text	English HS 중심	티 어 사 1,
NLI	ANLI	official GitHub, official data, HE, paper	facebook/anli	sentence pair	entailment/neutral/contradiction	어 기 t d t cc 과
NLI	FEVER	official data, HE, paper	fever 또는 custom adapter	claim/evidence pair	supports/refutes/not enough info	lo 어 P P st ur te
Sentiment	IMDB	Stanford data, HE, paper	stanfordnlp/imdb 또는 imdb	long single text	positive/negative	어 음 st 는
Sentiment	TweetEval sentiment	official GitHub, sentiment files, HE, paper	cardiffnlp/tweet_eval , config sentiment	tweet text	negative/neutral/positive	어 t 사 4: pi 있 록
Dialects	Aepli/VarDial 2023 계열	VarDial shared tasks, SID4LR data/baseline, findings paper	custom/local 검증 필요	single text 또는 intent utterance	dialect/intent labels	A V: tr te st cl i 쓸 id 저
Dialects	Multi-VALUE	GitHub, HF collection, paper	fixed single HF dataset 없음. value-nlp toolkit 또는 SALT-NLP HF variants	transformed item	dialect 또는 variant labels	fr st st cl sc 예

Dataset adapter 공통 필수 항목:

- [dataset_name](#)
- [task_family](#)
- [input_type](#): [single_text](#) 또는 [sentence_pair](#)
- [label_names](#) 와 label id mapping
- [train/dev/test](#) split method, official link, dataset revision, generated split seed/hash
- [num_labels](#), split size, class distribution

4. 모델 설정

Role	Model	Layers	Hidden size	사용 방식
Teacher	<code>bert-base-uncased</code>	12	768	dataset별 fine-tuning 후 freeze
Student	<code>TinyBERT_General_4L_312D</code>	4	312	모든 condition에서 동일 public checkpoint로 초기화

구현 계약:

- teacher는 dataset마다 별도로 fine-tuning한다.
- student training 중 teacher는 `eval()` 상태이며 gradient를 계산하지 않는다.
- student는 모든 condition에서 같은 checkpoint에서 시작해야 한다.
- tokenizer는 teacher/student 모두 `bert-base-uncased`를 사용한다.
- `token_type_ids`가 필요한 sentence-pair task에서는 teacher/student 입력 정책을 metadata에 기록한다.
- public TinyBERT checkpoint는 이미 general distillation을 거친 것으로 간주하되, 본 실험은 task-specific signal ablation만 수행한다.

Layer mapping in Hidden loss:

Student layer	Teacher layer
1	3
2	6
3	9
4	12

5. Training recipe

핵심 정의

이 프로젝트의 task-specific training은 순차 학습이 아니다.

```
Initialization:
public TinyBERT_General_4L_312D checkpoint load

Joint training:
condition에 포함되는 모든 loss를 한 번에 넣고 training
예: kd_full = CE + LogitKD + HiddenKD + AttentionKD
예: kd_hidden_attn = CE + HiddenKD + AttentionKD
예: kd_logit = CE + LogitKD
```

다시 말해, `Hidden/Attention`을 먼저 맞춘 뒤 `Logit`을 나중에 맞추는 TinyBERT 원 논문의 task-specific 순차 recipe를 재현하지 않는다. 구현에는 intermediate 전용 training loop와 prediction 전용 training loop를 만들지 않는다.

Early stopping 계약

최신 결정상 teacher와 student 모두 early stopping을 사용할 수 있다.

대상	계약
Teacher	dataset별 dev primary metric 기준 early stopping 가능. 최종 frozen checkpoint를 모든 student condition에 공유
Student	early stopping 가능.
Test evaluation	early stopping 또는 dev checkpoint selection 후 test는 최종 1회 평가
Metadata	early stopping 사용 여부, monitor, patience, best step/epoch를 <code>run_metadata.json</code> 에 기록

- 고려사항
 - HP search를 하면 좋겠지만, 여건상 힘들 수도 있다.
 - 동일한 논리로 Student early stopping을 쓰더라도 condition별로 다른 patience나 metric을 쓰면 안 될 수도 있다. 이는 HP search로 간주될 수 있다.
 - 사실 HP세팅을 모두에게 해주는 것이 공정한 것이다. (동일하면 누구는 더 좋고 더 좋지 않을 수 있기 때문)

단일 HP 세트 (변경 가능. 단, 모든 세팅에서 동일해야함)

하나의 hyperparameter 세트를 모든 dataset과 condition에 공유한다. 구현자는 아래 값을 기본 config로 두고, 변경이 필요하면 전체 실험에 같은 변경을 적용해야 한다.

항목	기본 계약
seed	42
optimizer	AdamW
learning rate	2e-5
batch size	16 기본, 메모리 부족 시 gradient accumulation으로 effective batch size 유지
max epochs	3 기본
early stopping monitor	dev_macro_f1
early stopping mode	maximize
patience	2
max sequence length	모든 dataset/condition에서 128 고정
mixed precision	hardware에 맞춰 전체 run에서 일관되게 적용

6. Loss 구현 명세

각 batch에서 total loss는 활성화된 항만 더한다.

```
L_total =  
1.0 * L_CE  
+ 1.0 * I_logit * L_logit  
+ 1.0 * I_hidden * L_hidden  
+ 1.0 * I_attention * L_attention
```

`I_logit`, `I_hidden`, `I_attention` 은 condition별 on/off indicator이다.

CE

```
L_CE = CrossEntropy(y_gold, logits_student)
```

구현 계약:

- 모든 condition에 포함한다.
- weighted CE, label smoothing은 main 설정에 넣지 않는다.
- label mapping은 teacher/student/run 전체에서 동일해야 한다.

Logit KD

```
p_t = softmax(z_teacher / T)  
p_s = softmax(z_student / T)  
L_logit = T^2 * KL(p_t || p_s)  
T = 1.0
```

구현 계약:

- KL 방향은 `KL(teacher || student)` 이다.
- `T^2` scaling을 적용한다.
 - `T` 는 temperature
- `T=1.0` 으로 고정한다.
- teacher logits는 `detach()` 한다.

Hidden KD

Teacher hidden size는 768, student hidden size는 312이므로 trainable projection `312 -> 768` 을 둔다.

```
L_hidden =
  mean_over_mapped_layers(
    mean_over_valid_tokens_and_hidden_dim(
      || P_l(h_student_l) - h_teacher_m ||_2^2
    )
  )
```

구현 계약:

- projection은 mapped student layer별 trainable linear layer로 둔다.
- valid token은 `attention_mask == 1` 인 token이다.
- 평균 denominator는 `valid token count x hidden dim` 이다.
- teacher hidden은 `detach()` 한다.
- tokenizer와 truncation이 teacher/student에서 같아야 한다.

Attention KD

```
L_attention =
  mean_over_mapped_layers(
    mean_over_valid_token_pairs_and_heads(
      || A_student_l - A_teacher_m ||_2^2
    )
  )
```

구현 계약:

- attention probability를 사용한다.
- valid token pair는 query/key 양쪽 모두 non-padding인 pair이다.
- 평균 denominator는 `valid token pair count x head count` 이다.
- teacher/student head 수가 다르면 양쪽 attention을 head dimension에서 평균한 뒤 MSE를 계산한다.
- teacher attention은 `detach()` 한다.
- attention heatmap은 exploratory artifact이며 causal explanation으로 쓰지 않는다.

Loss logging

모든 run은 아래 component를 training log에 남긴다.

Field	설명
<code>loss_total</code>	backward에 사용한 최종 loss
<code>loss_ce</code> , <code>raw_loss_ce</code>	CE weighted/raw
<code>loss_logits</code> , <code>raw_loss_logits</code>	Logit KD weighted/raw, 비활성 조건은 null
<code>loss_hidden</code> , <code>raw_loss_hidden</code>	Hidden KD weighted/raw, 비활성 조건은 null
<code>loss_attention</code> , <code>raw_loss_attention</code>	Attention KD weighted/raw, 비활성 조건은 null
<code>grad_norm</code>	student gradient norm
<code>learning_rate</code>	current LR
<code>epoch</code> , <code>global_step</code>	progress metadata
<code>training time per epoch</code> , <code>total training time</code>	

7. 평가 지표

Main performance

Metric	역할
<code>macro_f1</code>	primary metric
<code>micro_f1</code>	secondary metric, 전체 instance-level F1
<code>accuracy</code>	secondary metric

Metric	역할
<code>per_class_f1</code>	class별 개선/악화 확인
<code>confusion_matrix</code>	오류 이동과 class-pair 변화 확인

Calibration

Metric	방향
<code>ECE</code>	낮을수록 좋음
<code>NLL</code>	낮을수록 좋음
<code>Brier</code>	낮을수록 좋음

Teacher-student analysis

Metric	목적
<code>top1_agreement</code>	teacher/student argmax 일치율
<code>teacher_student_kl</code>	$KL(p_{\text{teacher}})$
<code>teacher_correct_student_wrong</code>	student가 못 배운 teacher knowledge
<code>teacher_wrong_student_correct</code>	student가 teacher보다 나은 case
<code>error_copying</code>	teacher와 student가 같은 오답을 낸 case

Efficiency

Metric	측정
<code>latency_p50_ms</code> , <code>latency_p95_ms</code>	warmup 후 fixed batch inference
<code>throughput_samples_per_sec</code>	fixed hardware/batch
<code>model_size_mb</code>	serialized checkpoint size
<code>parameter_count</code>	trainable/total parameter
<code>gpu_memory_mb</code>	peak memory

Attention heatmap

Attention heatmap은 representative examples에 대해 저장한다. 필수 비교는 `ce_only` vs KD 조건, teacher vs student, correct vs wrong case이다.

저장 단위:

- dataset
- condition
- split
- example_id
- mapped layer pair
- head strategy: `original_heads` 또는 `mean_heads`
- token list
- attention matrix

Similarity between Layers

Layer similarity는 mapped layer pair마다 계산한다.

Metric	대상	설명
<code>cosine_similarity</code>	projected student hidden vs teacher hidden	valid token hidden vector 기준 평균
<code>kl_divergence</code>	attention distribution 우선 적용	$KL(\text{teacher}, \text{student})$

구현 계약:

- hidden similarity는 `Pl(hstudent)` 와 `hteacher` 를 비교한다.

- token-level cosine을 valid token에 대해 평균하고, layer별/condition별 값을 저장한다.
- KL은 확률 분포가 필요한 지표이므로 attention distribution에 우선 적용한다.
- hidden vector에 KL을 적용할 경우 softmax 또는 normalization 방법을 metadata에 명시한다.
- metric 이름은 artifact에서 `layer_cosine_similarity`, `layer_kl_divergence` 로 고정한다.

8. 필수 구현 체크리스트

Dataset

- main 9개 dataset config가 모두 존재한다.
- 모든 adapter가 `train/dev/test` 를 노출한다.
- label mapping이 run 전체에서 고정된다.
- sentence-pair dataset은 `text_a`, `text_b`, `token_type_ids` 정책을 명시한다.
- custom/local dataset은 raw file hash와 split index hash를 저장한다.

Model

- teacher는 dataset별 `bert-base-uncased` fine-tuning 후 freeze한다.
- student는 모든 condition에서 같은 `TinyBERT_General_4L_312D` checkpoint로 시작한다.
- tokenizer는 `bert-base-uncased` 로 통일한다.
- layer mapping은 `1->3`, `2->6`, `3->9`, `4->12` 로 고정한다.
- random-init baseline을 만들지 않는다.

Training

- seed는 모든 실행에서 `42` 다.
- hyperparameter search를 하지 않는다.
- 순차 distillation training을 구현하지 않는다.
- task-specific training은 활성화된 모든 loss를 한 번에 넣는 joint training이다.
- student early stopping을 쓰는 경우 8개 condition에 같은 rule을 적용한다.
- teacher는 student training 중 `eval()` 과 `no_grad()` 상태다.
- component loss와 raw loss를 모두 logging한다.
- 각 train마다 알맞은 모델 경로에 에포크당 모든 checkpoint를 다 저장한다.

Loss

- CE는 모든 condition에 포함된다.
- Logit KD는 $T^2 * KL(\text{teacher} || \text{student})$ 이며 $T=1.0$ 이다.
- Hidden KD는 projection `312 -> 768` 을 사용한다.
- Hidden KD는 valid token x hidden dim 평균이다.
- Attention KD는 valid token pair x head 평균이다.
- head mismatch 시 head 평균 전략을 사용한다.

Evaluation

- `macro_f1` 을 primary metric으로 저장한다.
- `micro_f1` 을 반드시 저장한다.
- `accuracy`, `per_class_f1`, `confusion_matrix` 를 저장한다.
- `ECE`, `NLL`, `Brier` 를 저장한다.
- `top1_agreement`, `teacher_student_kl`, `error_copying` 을 저장한다.

- latency, throughput, model size를 측정한다.
- attention heatmap을 artifact로 저장한다.
- layer similarity의 Cosine Sim , KL Divergence 를 저장한다.
- factorial main effect와 interaction effect를 계산한다.

9. 구현 중 금지/주의 사항

항목	계약
TinyBERT exact reproduction	하지 않는다
Task-specific sequential KD	하지 않는다
Intermediate KD 후 prediction KD 분리	하지 않는다
Random-init baseline	만들지 않는다
Data augmentation	넣지 않는다
HP search	하지 않는다
Seed 변경	42 외 값 사용 금지
Condition별 다른 training rule	금지
Condition별 다른 early stopping 설정	금지
Test set 반복 튜닝	금지